

Trabajo Fin de Máster : Pipeline de Datos Ferroviarios en Azure

Opción 2: Preparación de un pipeline de datos.

Tecnologías utilizadas: Preparación y Explotación de Datos con Spark, Cosmos DB y FastAPI

Autor: Judith Castillo Martínez

Introducción

Desarrollo de un pipeline de datos ferroviarios en Azure.



Objetivo: preparar y disponibilizar datos.



Tecnologías: Spark (PySpark), Databricks, Azure, Cosmos DB, FastAPI.

Configuración inicial

Configuración del espacio en Azure

Data Lake

Clústeres de Databricks

Cosmos DB (API MongoDB)

Entorno seguro, escalable y listo para ejecutar el pipeline.

Estructura del pipeline

El pipeline
se
compone
de 4
grupos de
notebooks:

- 1. Autodescarga
- 2. Ingesta (RAW)
- 3. Limpieza (CLEAN)
- 4. Publicación (Cosmos DB).

1. Autodescarga



SCRIPT PARA DESCARGAR
AUTOMÁTICAMENTE LOS
FICHEROS GTFS.



SE ALMACENAN EN EL DATA LAKE
SIN INTERVENCIÓN MANUAL.

2. Ingesta en RAW

Los datos se guardan en la capa RAW en formato Delta.

Se conserva el formato original con versionado y trazabilidad.

3. Limpieza en CLEAN

12 notebooks de transformación.

Reglas de calidad

Eliminación de duplicados

Validación de horarios

Estandarización de nombres.

Resultado: datos coherentes y listos para análisis.

4. Publicación en Cosmos DB

Carga de datos limpios en Cosmos DB (API MongoDB).



Se generan identificadores únicos.



Las tablas se exponen como colecciones listas para consulta.

Job en Databricks (Orquestación)

Se creó un **Job en Databricks** que encadena las etapas en orden: autodescarga → ingesta → limpieza → carga.

Este Job asegura la **ejecución secuencial, trazabilidad y control de errores**, facilitando la operación y la repetibilidad del pipeline.

Explotación con FastAPI



API desarrollada en FastAPI sobre las colecciones de Cosmos DB.

Endpoints disponibles: rutas, viajes, paradas, tiempos de paso.

Despliegue en Azure App Service.

Consumo desde aplicaciones o herramientas de BI.

Conclusión



Pipeline en Azure con ciclo completo de datos.



Desde ingesta automática hasta exposición en API moderna.



Flujo orquestado, escalable y alineado con el negocio ferroviario.